Tarea 1 — PostGIS de punta a punta: Santiago centro

Bastian Sandoval · Procesamiento Masivo de Datos · USM 2026-2 · Paralelo 701

Fuentes de todas las conclusiones. OSM: extracto `chile-latest` de Geofabrik, datos al **02-10-2026** (20:21 UTC), lo que la comunidad dibujó. GTFS: DTPM `GTFS_20261003.zip` (`feed_version V168.20261003`, vigencia 03-10 a 31-12-2026), lo que el operador declara; el enunciado nombra `GTFS_20260829.zip`, que ya no era el vigente al descargar (03-10-2026). Comunas: DPA 2023 (INE). Zona: caja lon −70,75…−70,52 · lat −33,52…−33,36, todo en **SRID 5361**. De las 30 comunas que tocan la caja, 13 quedan completas; las otras 17 están cortadas y sus cifras valen sólo para la parte dentro de la caja. Consultas, resultados y planes completos: `resultados/q*.txt`.

P1. Paraderos por comuna

Hay **6.569 paraderos de bus** del GTFS en la zona: **17,3 por km²**.

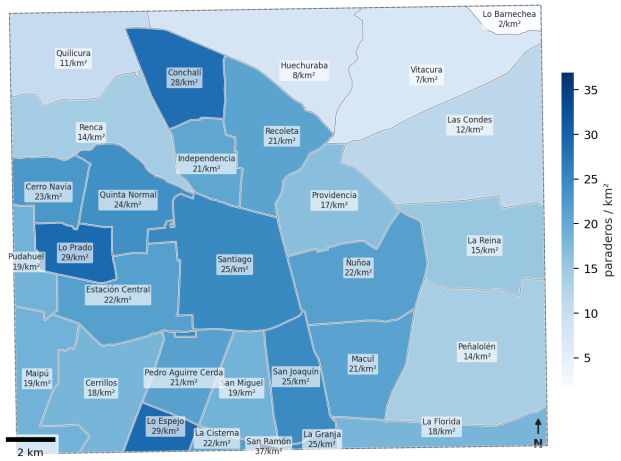
Más densas (completas)	par.	par./km²	Menos densas	par.	par./km²
Lo Prado	191	29,2	Lo Barnechea (cortada)	5	1,8
Conchalí	311	28,4	Vitacura (cortada)	194	7,4
Santiago	573	24,7	Huechuraba (cortada)	165	7,9
San Joaquín	244	24,6	Quilicura (cortada)	178	10,7
Quinta Normal	282	23,9	Las Condes (cortada)	364	11,8

Interpretación. Según el GTFS de la DTPM (vigente desde el 03-10-2026), la red de paraderos es más densa en las comunas chicas y compactas del centro-poniente y norte (Lo Prado, Conchalí) que en Santiago mismo, y cae a menos de la mitad en el nororiente (Vitacura, Huechuraba, Las Condes), donde hay cerros, parques y manzanas grandes. Santiago es la que más paraderos tiene (573). Entre las comunas completas la menos densa es Providencia (16,8).

Plan. *Nested Loop*: por cada una de las 67 piezas de `comunas_zona_sub` (tabla externa, *Seq Scan*) se hace un *Index Scan* sobre `paraderos_gtfs_geom_gist` con `geom && s.geom`; el índice está del lado de los paraderos, la tabla grande. Después `ST_Intersects` descarta los falsos positivos del bbox (48 por pieza). Con índice: 40 ms. Sin índice: 120 ms, con *Seq Scan* de paraderos y un join que compara todo contra todo (433.554 pares descartados por el filtro).

P1 · Densidad de paraderos de bus por comuna

Paraderos GTFS (modo bus) por km² de comuna dentro de la caja santiago-centro



Comunas cortadas por la caja: el área y los paraderos se cuentan sólo dentro de la caja.
Fuentes: OSM © colaboradores de OpenStreetMap, ODbL (chile-261002.osm.pbf, datos al 2026-10-02) · GTFS DTPM GTFS_20261003.zip (feed_version V168.20261003, vigencia 20261003 a 20261231) · DPA 2023 INE. SRID 5361.

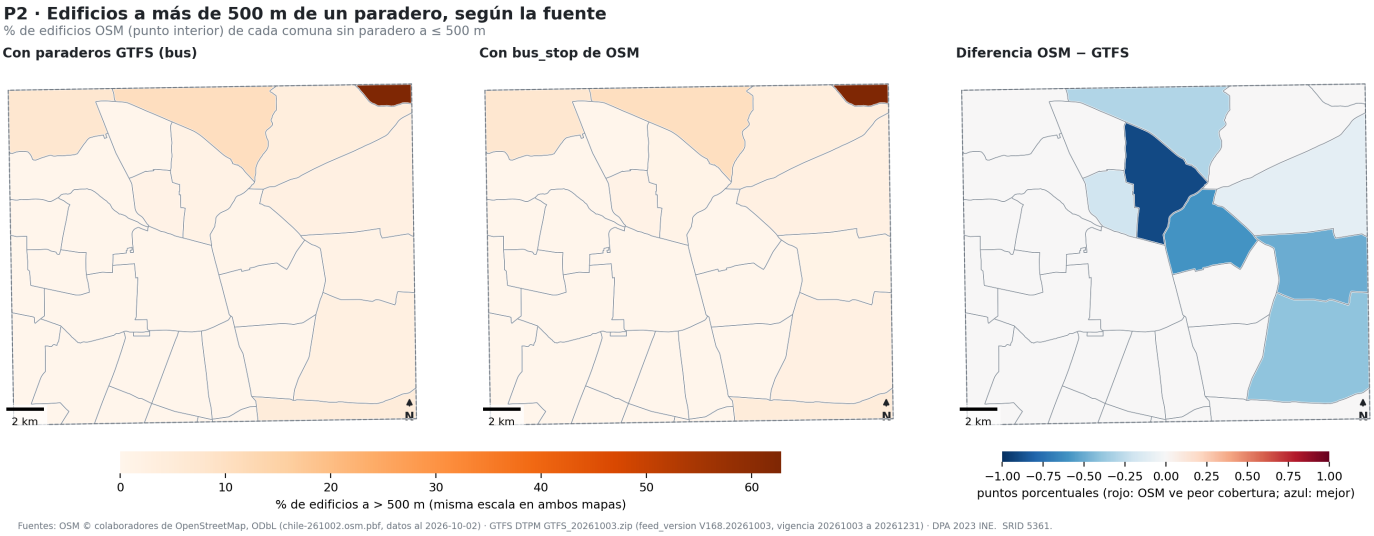
P2. Cobertura a 500 m (GTFS contra OSM)

De 118.821 edificios de OSM, el **1,14 %** queda a más de 500 m de un paradero de bus del GTFS y el **0,98 %** a más de 500 m de un `bus_stop` de OSM.

Comuna	edificios	% lejos (GTFS)	% lejos (OSM)	dif. (pp)
Lo Barnechea (cortada, 78 edificios)	78	62,8	62,8	0,0
Huechuraba	1.269	10,7	10,4	−0,3
Quilicura	2.291	7,5	7,5	0,0
La Florida	965	4,7	4,7	0,0
Vitacura	4.017	3,9	3,9	0,0
16 comunas (Santiago, Ñuñoa, Macul, …)		0,0	0,0	0,0

Interpretación. La conclusión **no cambia con la fuente**: las cinco comunas peor cubiertas son las mismas y en el mismo orden, y la mayor diferencia es de 0,9 puntos (Recoleta). OSM da una cobertura levemente mejor porque incluye algunos `bus_stop` que el GTFS no declara. La falta de cobertura está en los bordes de la caja (faldeos de Huechuraba, Quilicura, Lo Barnechea), no en el centro. Dos cautelas: el dato dice “hay un paradero cerca”, no cuántos buses pasan (eso es P7), y los edificios son los que alguien dibujó en OSM, con cobertura desigual entre comunas.

Plan. Dos *Nested Loop Anti Join*: por cada edificio, un *Index Scan* sobre `paraderos_gtfs_geom_gist` (o `paraderos_osm_geom_gist`) con `geom && ST_Expand(punto, 500)`. `ST_DWithin` se convierte en una caja de ±500 m que resuelve el GIST, y basta una fila para descartar el edificio. El índice está del lado de los paraderos; los edificios se recorren completos. Total: 4,2 s para 118.821 edificios. Sin índice el plan estimado es un anti-join con *Seq Scan* de paraderos por cada edificio (118.821 × 6.569 distancias), con costo estimado de $4{,}1 \times 10^9$.



P3. Dos fuentes, un objeto

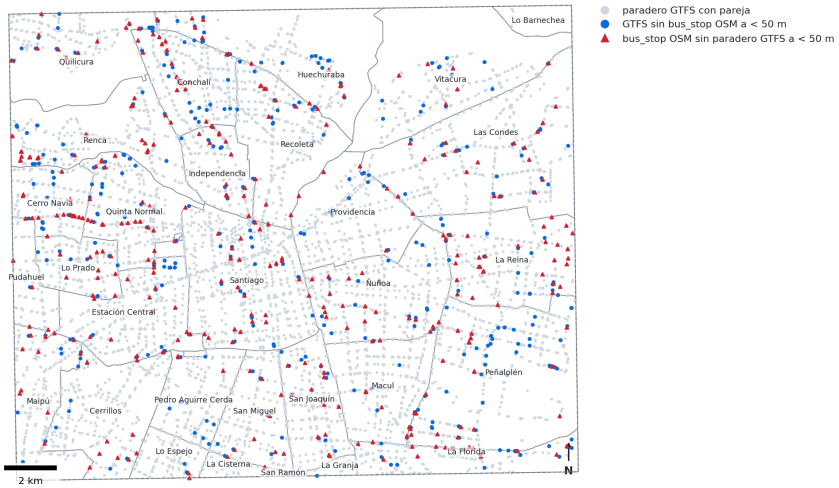
Sentido (radio 50 m)	total	sin pareja	%
Paraderos GTFS (bus) sin `bus_stop` OSM cerca	6.569	380	5,8
`bus_stop` OSM sin paradero GTFS cerca	6.568	364	5,5

Sensibilidad al radio: con 25 m quedan 1.003 y 995 sin pareja; con 100 m, 141 y 137.

Interpretación. Las dos fuentes tienen casi el mismo tamaño y coinciden en el 94 % de los casos a 50 m, lo que sugiere que en Santiago los `bus_stop` de OSM (al 02-10-2026) vienen en buena parte de una importación de datos oficiales y no de dibujo independiente. Ninguna es claramente más completa: a OSM le faltan 380 paraderos que el operador declara (más en Peñalolén, 45, y Quinta Normal, 25), y OSM tiene 364 que el GTFS vigente no declara (más en La Reina, 30), que pueden ser paraderos retirados o de servicios fuera del sistema. El resultado depende del radio: a 25 m los “sin pareja” casi se triplican, así que parte de la diferencia es posición y no existencia.

P3 · Paraderos sin pareja en la otra fuente (radio 50 m)

380 paraderos GTFS sin bus_stop OSM · 364 bus_stop OSM sin paradero GTFS



Fuentes: OSM © colaboradores de OpenStreetMap, ODbL (chile-261002.osm.pbf, datos al 2026-10-02) · GTFS DTPM GTFS_20261003.zip (feed_version V168.20261003, vigencia 20261003 a 20261231) · DPA 2023 INE. SRID 5361.

P4. Kilómetros de recorrido por comuna y efecto de ST_Subdivide

Comuna	km	rutas	km/km²	Comuna	km	rutas	km/km²
Santiago	1.149,9	156	49,6	Ñuñoa	417,5	60	24,7
Las Condes	616,2	73	19,9	Providencia	399,1	81	27,6
Estación Central	534,3	81	37,2	Vitacura	311,3	40	11,8
Peñalolén	459,7	68	14,9	Lo Barnechea	7,7	10	2,7

Total en la zona: 8.444 km de trazado (un shape principal por ruta y sentido; GTFS del 03-10-2026).

Interpretación. Santiago concentra el 14 % de los km con el 6 % de la superficie: 156 de las 347 rutas pasan por ella. Le siguen en intensidad Estación Central (37,2 km/km²) y Lo Prado (33,8), los corredores de entrada desde el poniente. Vitacura y Huechuraba tienen la cuarta parte de la intensidad de Santiago.

ST_Subdivide. Mismo resultado (8.444,28 km) por los dos caminos: contra las 30 comunas completas, **439 ms**; contra las 67 piezas de `ST_Subdivide(geom, 128)`, **558 ms** (mejor de 3 corridas). Aquí subdividir **no ayudó**: las comunas ya están recortadas a la caja y tienen 191 vértices en promedio (88 por pieza), así que `ST_Intersection` ya era barata, y con piezas hay más pares que intersectar (4.070 contra 2.589). Subdividir rinde con polígonos de miles de vértices. En ambos planes el índice usado es `recorridos_geom_gist`, del lado de los recorridos, y filtra poco: descarta 119–132 filas por cada 61–86 que sirven, porque el bbox de una línea de 20 km cubre media ciudad.

P5. Vecino más cercano (recorrido 506)

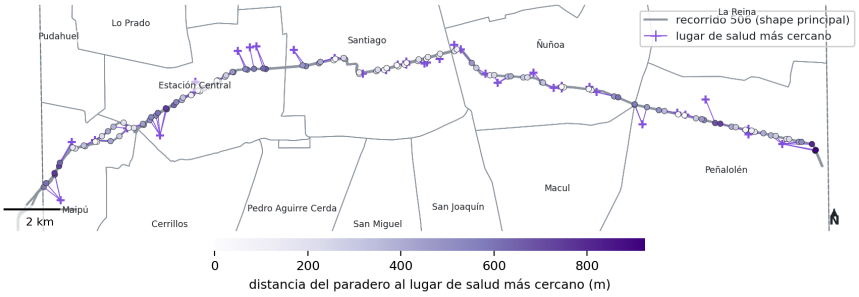
El 506 tiene **117 paraderos** en la zona (los dos sentidos). La farmacia o centro de salud más cercano de OSM está en promedio a **340 m** (mediana 308 m, máximo 924 m); **30 paraderos (26 %)** lo tienen a más de 500 m. El más cercano es una farmacia en 58 casos, una clínica o CESFAM en 39 y una consulta (`doctors`) en 20; nunca un hospital.

Interpretación. A lo largo del 506 (Maipú–Peñalolén por 5 de Abril, Av. Matta y Av. Grecia) el acceso a salud es bueno en el tramo central (decenas de metros en Av. Matta) y peor en los dos extremos: Pajaritos (583–736 m) y el final en Diagonal Las Torres (802–924 m). Depende de qué farmacias están dibujadas en OSM al 02-10-2026; en la periferia pueden faltar.

Plan. Por cada paradero: `Limit` → *Index Scan* sobre `amenidades_geom_gist` con `Order By: geom <-> p.geom`. El GIST entrega las amenidades ya ordenadas por distancia y se detiene en la primera que cumple el filtro de `amenity` (descarta 16 antes de encontrarla). El índice está del lado de las amenidades. Con índice: 12 ms. Sin índice: 446 ms, con *Seq Scan* de las amenidades de salud y un *Sort* por distancia repetido 117 veces.

P5 · Salud más cercana a cada paradero del recorrido 506

Farmacia, hospital, clínica o consulta (OSM) más cercana a cada paradero; KNN con <->



Fuentes: OSM © colaboradores de OpenStreetMap, ODbL (chile-261002.osm.pbf, datos al 2026-10-02) · GTFS DTPM GTFS_20261003.zip (feed_version V168.20261003, vigencia 20261003 a 20261231) · DPA 2023 INE. SRID 5361.

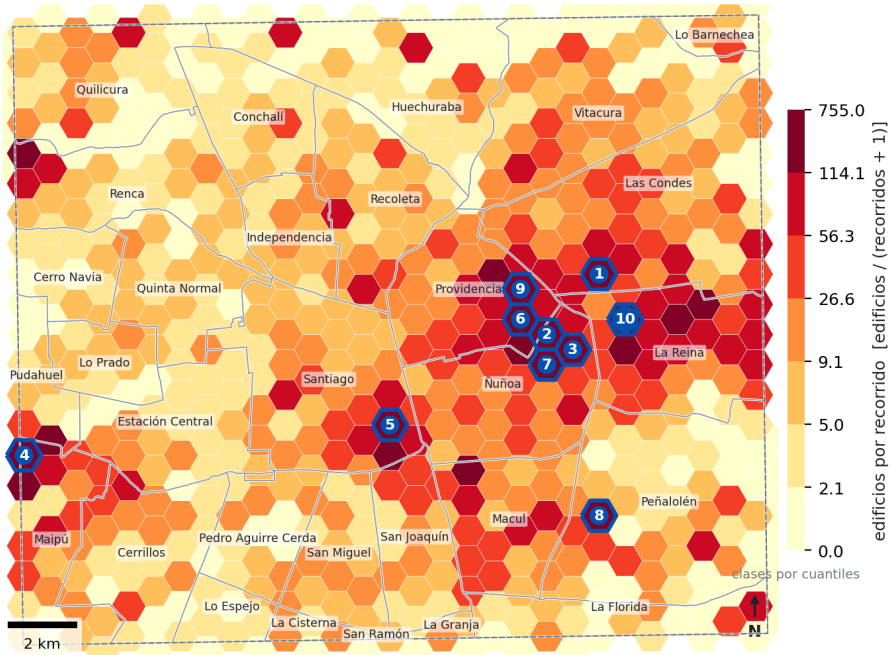
P6. Grilla hexagonal de 500 m (mapa principal)

636 celdas; en promedio 186,8 edificios y 11,5 recorridos distintos por celda. 59 celdas no tienen ningún recorrido, y 4 de ellas tienen 50 edificios o más. Criterio del ranking: índice = edificios / (recorridos + 1), sólo celdas con al menos 50 edificios.

#	Comuna	edif.	rec.	índice	#	Comuna	edif.	rec.	índice
1	Las Condes	755	0	755,0	6	Providencia	1.028	3	257,0
2	Ñuñoa	1.344	3	336,0	7	Ñuñoa	765	2	255,0
3	Ñuñoa	1.321	3	330,3	8	Peñalolén	702	2	234,0
4	Maipú	2.532	7	316,5	9	Providencia	456	1	228,0
5	Santiago	2.450	7	306,3	10	La Reina	894	3	223,5

P6 · Dónde hay muchos edificios y pocos recorridos

Grilla hexagonal (lado 500 m). Color: edificios / (recorridos distintos + 1). Contorno: las 10 celdas con índice más alto (≥ 50 edificios)



Recorridos distintos = count(DISTINCT route_id) de todos los shapes GTFS que cruzan la celda.
Fuentes: OSM © colaboradores de OpenStreetMap, ODbL (chile-261002.osm.pbf, datos al 2026-10-02) · GTFS DTPM GTFS_20261003.zip (feed_version V168.20261003, vigencia 20261003 a 20261231) · DPA 2023 INE. SRID 5361.

Interpretación. Las celdas con mucha ciudad y poca oferta se agrupan en el límite Providencia–Ñuñoa–Las Condes–La Reina (7 de las 10): barrios residenciales de casas, muy bien dibujados en OSM, donde los buses van por las avenidas

del borde y no entran. La correlación entre edificios y recorridos por celda es baja (**r = 0,19**): los recorridos siguen ejes, no la cantidad de edificios. Cautela: el índice cuenta edificios, no habitantes (una torre vale lo mismo que una casa), y favorece a las comunas donde OSM está más detallado. El conteo incluye las líneas de Metro cuyo trazado cruza la celda; por estas 10 no cruza ninguna (todos sus recorridos son de bus) y la estación más cercana queda a entre 0,5 y 1,4 km del centro de cada celda. Datos: OSM al 02-10-2026, GTFS vigente desde el 03-10-2026.

Plan. *Function Scan* sobre `ST_HexagonGrid` (636 celdas) y, por celda, dos *Index Scan*: `edificios_punto_gist` (puntos: 187 filas útiles y 63 descartadas) y `recorridos_geom_gist` (líneas: 23 útiles y 100 descartadas). El segundo se lleva la mayor parte de los 1,3 s.

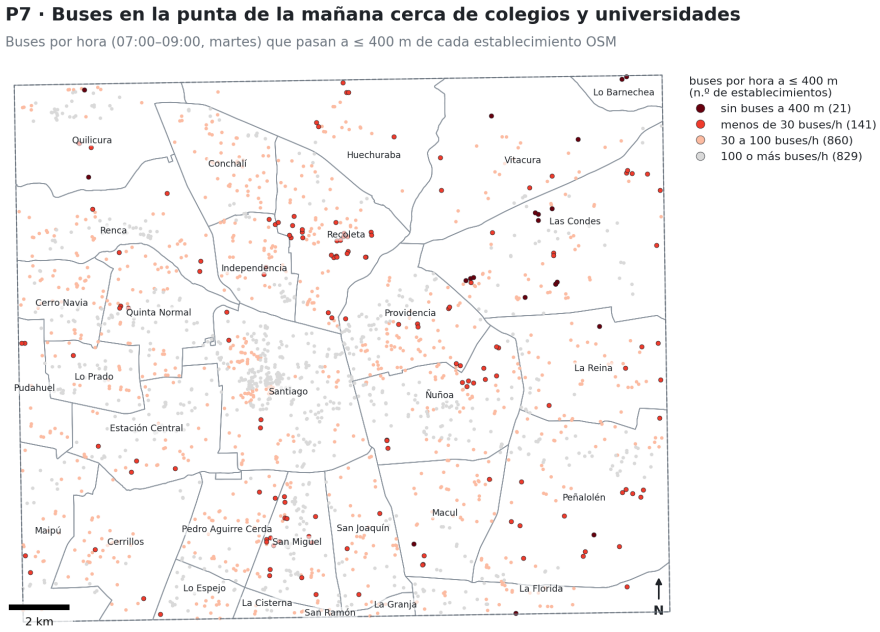
P7 (propia). Buses en la punta de la mañana cerca de establecimientos educacionales

Para cada colegio, instituto o universidad de OSM (1.851) se cuentan los buses por hora que pasan a 400 m o menos entre 07:00 y 09:00 de un martes, con horarios reconstruidos desde `frequencies.txt`. Cruza OSM (establecimientos) con GTFS (paraderos y frecuencias), y a diferencia de P2 mide cuánto servicio hay, no sólo si hay un paradero.

Categoría	establecimientos	%
Sin buses a 400 m	21	1,1
Menos de 30 buses/h	141	7,6
30 a 100 buses/h	860	46,5
100 o más buses/h	829	44,8

Mediana: 91 buses/h (percentil 10: 32; percentil 90: 225,5).

Interpretación. El 91 % de los establecimientos tiene 30 o más buses por hora a distancia caminable en la punta; el 8,7 % (162) tiene menos de 30 o ninguno. Los mal servidos se concentran en Recoleta (29,5 % de sus establecimientos), Huechuraba (27,3 %), Las Condes (24,4 %) y Vitacura (20,0 %); en Santiago es el 1,3 % y la mediana llega a 165,5 buses/h. De los 15 peor servidos con nombre, 7 son colegios de Las Condes, a 430–510 m del paradero más cercano. Válido para el GTFS vigente desde el 03-10-2026 y los establecimientos dibujados en OSM al 02-10-2026; un campus grande se mide desde su punto interior, lo que explica el caso del Campus San Joaquín de la PUC.



Horarios reconstruidos desde frequencies.txt (los buses DTPM se publican por frecuencia).
Fuentes: OSM © colaboradores de OpenStreetMap, ODbL (chile-261002.osm.pbf, datos al 2026-10-02) · GTFS DTPM GTFS_20261003.zip (feed_version V168.20261003, vigencia 20261003 a 20261231) · DPA 2023 INE. SRID 5361.

Decisiones del pipeline

- **SRID 5361 en todo.** Unidades en metros: `ST_DWithin(a, b, 500)` son 500 m reales y usa el GIST. OSM se reproyecta al cargar (`ogr2ogr -t_srs`), el GTFS se construye en 4326 y se transforma, la DPA ya viene en 5361.

- **Recorte en la base.** `osmium` recorta el PBF de Chile (333 MB → 17 MB); el GTFS se filtra con `ST_Intersects` contra la caja; las comunas se recortan a la caja para que áreas, conteos y km se midan sobre la misma superficie.
- **Punto interior contra polígono.** `edificios` guarda el polígono (para áreas) y `punto = ST_PointOnSurface(geom)`. Contar, asignar a comuna o celda y medir distancias se hace con el punto: cada edificio cae en un solo lugar. No se usa el centroide porque en un edificio en L puede caer fuera. Las amenidades dibujadas como polígono (hospitales) entran con su punto interior.
- **Reparaciones.** De 146.755 multipolígonos de OSM, **15 inválidos** (14 `Self-intersection`, 1 `Ring Self-intersection`), todos reparados con `ST_MakeValid` + `ST_CollectionExtract(…, 3)`; ninguno quedó vacío. Líneas inválidas: 0. Comunas inválidas en la DPA: 0.
- **GTFS con `COPY`.** `stop_times.txt` tiene 1.098.529 filas y `shapes.txt` 456.573 puntos; se cargan con `COPY` a tablas `UNLOGGED` de texto y el GTFS completo queda listo en 17 s.
- **Shapes múltiples por ruta.** 981 `shape_id` en el feed, 708 tocan la caja (347 rutas). Se guardan todos, una `LineString` por `shape_id` ordenada por `shape_pt_sequence::int` (como texto, `'10' < '9'`). `es_principal` marca el shape con más salidas por ruta y sentido (604): P4 usa sólo esos para no sumar la misma calle por cada variante; P6 cuenta `DISTINCT route_id`.
- **Buses por frecuencia.** En el GTFS de la DTPM los `stop_times` de bus son plantillas que parten a las 0:00:00; los horarios reales salen de expandir `frequencies.txt` (14.542 filas). P7 usa eso.
- **`ST_Subdivide`.** 30 comunas → 67 piezas. Sirve para el punto-en-polígono (P1, P2, P7); en P4 no mejoró el tiempo (ver P4).
- **Índices.** GIST en cada geometría derivada y B-tree en claves y filtros. Según `pg_stat_user_indexes` (reiniciado antes de las consultas), los más usados fueron `paraderos_gtfs_geom_gist` (148.862 veces), `paraderos_osm_geom_gist` (145.097) y `comunas_zona_sub_geom_gist` (120.673). **No se usaron**: `edificios_geom_gist` y `calles_geom_gist` (4,9 y 4,2 MB; las preguntas usan el punto interior y ninguna usa calles), `recorridos_route_idx`, los dos índices de la grilla (se lee completa) y seis claves primarias.
- **Lo que no funcionó.** Una agregación de `stop_times` dentro de un CTE hizo que el planner estimara 1 fila y eligiera un nested loop que no terminaba; se resolvió materializando en una tabla temporal con `ANALYZE`. Detalle de ése y otros casos en el README, §7.
- **Tiempos.** Carga completa 124 s; consultas, GeoPackage y mapas 109 s.